

Aprendizaje Automático Relacional

Inteligencia Artificial – Ingeniería del Software
Curso 2025/2026

Propuesta de trabajo del profesor Pedro Almagro Blanco

1. Introducción y objetivos

El aprendizaje automático relacional es una subdisciplina del aprendizaje automático que se ocupa del desarrollo de modelos orientados al **aprendizaje a partir de datos relacionales** [1].


Es habitual utilizar la estructura matemática del **grafo** (grafo con propiedades en caso de que los datos posean propiedades además de participar en relaciones) para representar datos relacionales. A su vez, en los últimos años se han desarrollado bases de datos orientadas al almacenamiento y consulta de datos con una alta carga relacional. Estas bases de datos (que son más ágiles a la hora de consultar en base a relaciones) son denominadas **bases de datos en grafo** [6].


En los casos habituales de aprendizaje automático, los ejemplos están caracterizados normalmente por una serie de propiedades y no es necesario a priori capturar las relaciones entre los ejemplos a la hora de aprender. En el caso del aprendizaje automático relacional, los ejemplos poseen **relaciones** entre ellos (y éstas son tomadas en cuenta a la hora de generalizar) y opcionalmente, una serie de propiedades.

Existen varias metodologías que permiten aprender a partir de la información relacional en un conjunto de ejemplos, algunas de ellas son: la construcción manual de features relacionales (1), el aprendizaje de representaciones latentes en baja dimensión (2) y el uso de modelos específicos, como son las *Graph Neural Networks* [8], capaces de aprender tareas de regresión o clasificación sobre datos en forma de grafo (3).


En este trabajo, nos centraremos en la **construcción manual de features relacionales** (1) para abordar un problema de clasificación relacional. En la configuración básica, para aprender una tarea de clasificación sobre los nodos de una red, el objetivo es aprender una función que dadas las propiedades de un nodo en una red sea capaz de clasificar correctamente dicho nodo en una de las diferentes clases. Para ello, se espera que el sistema aprenda dicha función de clasificación a partir de una serie de ejemplos con nodos previamente clasificados, de los cuales se conocen sus propiedades.

En este trabajo, **diseñaremos y evaluaremos varios modelos de aprendizaje automático relacional para aprender a clasificar los nodos de un grafo a partir de sus propiedades y/o a partir de la información relacional**. Para ello, se utilizarán métricas propias de la teoría de grafos como propiedades predictivas de los nodos. Algunas de estas métricas están relacionadas con la *centralidad* [2], el *coeficiente de clustering* [4] o la *detección de comunidades* [3]. En los siguientes diagramas se da una representación gráfica de algunas de estas métricas:





El **objetivo principal** de esta propuesta es implementar modelos de clasificación de nodos en grafos. Para ello, caracterizaremos los nodos de un grafo a partir de información relacional (a través de métricas relacionadas con centralidad, detección de comunidades y clustering) y utilizaremos dicha caracterización para entrenar modelos ML estándar (árbol de decisión, redes neuronales, kNN...).



Una vez entrenados, los modelos ML deben ser capaces de clasificar nodos en base a su información relacional. Opcionalmente, se podrá enriquecer la caracterización de los nodos con propiedades específicas de éstos (en el caso de los grafos con propiedades).

Para ello, será necesario alcanzar los siguientes **objetivos específicos**:

1. Familiarizarse con los **conceptos básicos** de la teoría de grafos (al menos aquellos relacionados con la *centralidad*, la *detección de comunidades* y el *coeficiente de clustering*).
2. Familiarizarse con las **librerías** “NetworkX” y “Scikit-Learn” de Python.
3. **Generar distintos modelos** - combinación de conjuntos de propiedades (relacionales y/o no relacionales) y algoritmos de aprendizaje automático - **y evaluar su rendimiento** sobre un conjunto de evaluación.

4. Conocer, comprender y aplicar distintas técnicas para el **análisis de la utilidad de las métricas** relacionales, la estimación de hiper-parámetros, test estadísticos de correlación, etc., que ayuden al modelado y eviten el sobreajuste de éste a los datos de entrenamiento.
5. **Seleccionar**, de entre todos los modelos construidos, **aquel que realice una mejor clasificación** y que se considere que generaliza mejor.
6. **Documentar el trabajo** realizado usando un formato de artículo científico.
7. **Realizar una presentación** (*PDF*, *PowerPoint* o similar) de los resultados obtenidos.

Cabe destacar, que si **el estudiante** lo desea, **puede combinar o comparar** los modelos basados en construcción manual de features relacionales **con aproximaciones basadas en el aprendizaje de representaciones latentes** en baja dimensión (utilizando métodos como *Node2Vec* [7]) **y/o modelos específicos**, como son las *Graph Neural Networks* [8].

2. Descripción del trabajo

Metodología

A continuación, se describe con más detalle cómo debe llevarse a cabo el trabajo. Para la consecución de los objetivos específicos, existen multitud de referencias y material en la web con ejemplos y videos de apoyo. Una referencia útil a la hora de conocer diferentes métricas para los nodos de un grafo es “*Statistical analysis of network data with R*” de *Eric D. Kolaczyk* [5], donde se pueden encontrar los fundamentos del análisis de redes y una lista exhaustiva de métricas que pueden ser utilizadas como propiedades predictivas de los nodos.

Cada grupo de trabajo se encargará de una tarea de aprendizaje relacional eligiendo para ello un conjunto de datos relacional susceptible de ser atacado con la metodología propuesta. Algunas fuentes de las que obtener conjuntos de datos de este tipo son:

- <https://sites.google.com/site/ucinetsoftware/datasets/>
- <https://lings.org/datasets/>
- <https://public.websites.umich.edu/~mejn/netdata/>
- <https://github.com/benedekrozemberczki/datasets>
- <https://dataverse.harvard.edu/>
- <https://public.websites.umich.edu/~mejn/netdata/>
- <https://www.kaggle.com/datasets>

Una vez seleccionado el conjunto de datos con el que trabajar, se deberá consultar su idoneidad con el profesor. Para ello, el grupo deberá escribir un correo a palmagro@us.es con el asunto “Trabajo IAIS Relacional (Grupo X)” -donde el valor de X corresponderá al número del grupo de trabajo correspondiente- en el que indicará cuál es el conjunto de datos seleccionado y la tarea de aprendizaje propuesta. Una vez se reciba la confirmación del profesor se debe proceder, entonces, a analizar de manera exploratoria el conjunto de datos, obtener conjuntos de propiedades relacionales y/o no relacionales para los nodos, realizar análisis de correlaciones, entrenar los modelos (realizando ajuste de hiper-parámetros) a partir de conjuntos de entrenamiento y estimar su rendimiento sobre conjuntos de validación adecuados.

Las medidas a usar para ello serán las correspondientes para medición de errores en tareas de clasificación. Se valorará la realización de visualizaciones para el análisis en todas las fases. Se recomienda utilizar entornos de programación y presentación para *Python* como *Matplotlib* y/o *Jupyter Notebook*.

IMPORTANTE: En caso de no superar la evaluación práctica en alguna de las convocatorias, **será obligatorio el cambio de conjunto de datos** (confirmando su idoneidad nuevamente al profesor).

Modelos

Se deben construir al menos **tres modelos de clasificación** relacionales, aunque pueden ser más, para poder realizar comparativas de rendimiento. La finalidad de construir varios modelos estriba en disponer de diferentes opciones entre las que elegir aquella que tenga una mejor combinación de métricas relacionales y/o propiedades nativas y algoritmo de aprendizaje. Es decir, aquella combinación que generaliza mejor. Esta capacidad de generalización es lo que se estima mediante el subconjunto de validación a la hora de entrenar el modelo.

Documentación y entrega

El trabajo deberá documentarse siguiendo un formato de artículo científico, con una extensión mínima de 6 páginas. En la página web de la asignatura se pueden encontrar plantillas donde se sugiere una estructura general. Estas plantillas siguen el formato de los *IEEE conference proceedings*, en cuyo sitio web se puede encontrar la guía para autores que ofrece información más detallada. El documento entregado deberá estar en formato PDF. Se valorará el uso del sistema LATEX. En el caso concreto de este trabajo, la memoria deberá al menos incluir: introducción; descripción del conjunto de datos y la tarea de predicción a realizar; descripción de las métricas relacionales utilizadas; descripción de los algoritmos de aprendizaje automático utilizados, explicando las dificultades encontradas y las decisiones de diseño adoptadas para abordarlas; descripción de los resultados alcanzados; conclusiones; bibliografía. **En ningún caso debe incluirse código en la memoria.**

La entrega del trabajo consistirá en un único fichero *zip* conteniendo la memoria del trabajo, el código implementado (ficheros *.py* o cuadernos de Jupyter) y el conjunto de datos utilizado.

Presentación y defensa

Como parte de la evaluación del trabajo se deberá realizar una defensa del mismo, para lo que se citará a los alumnos de manera conveniente. El día de la defensa se deberá realizar una pequeña presentación (*PDF*, *PowerPoint* o similar) de unos 20 minutos en la que deberán participar activamente todos los miembros del grupo que ha desarrollado el trabajo. Esta presentación deberá seguir a grandes rasgos la misma estructura que la memoria del trabajo, haciendo especial mención a los resultados obtenidos y al análisis crítico de los mismos. Se podrá usar un portátil (personal del alumno) y diapositivas. En los siguientes 5 minutos de la defensa, el profesor procederá a realizar preguntas sobre el trabajo, que podrán estar relacionadas tanto con la memoria como con el código fuente.

3. Evaluación del trabajo

Para que el trabajo pueda ser evaluado, se deben haber construido al menos tres modelos de clasificación relacionales. Además, es imprescindible asegurarse que todo el código proporcionado, librerías auxiliares, conjuntos de datos, etc., se pueden ejecutar en un notebook o fichero .py en una máquina independiente. Para la evaluación del trabajo se tendrán en cuenta los siguientes criterios, considerando una nota total máxima de 4 puntos:

1. **Memoria del trabajo:** se valorará la claridad de las explicaciones, el razonamiento de las decisiones, el análisis y presentación de resultados y el correcto uso del lenguaje. La elaboración de la memoria debe ser original, por lo que no se evaluará el trabajo si se detecta cualquier copia del contenido.
2. **Código fuente:** se valorará la claridad y buen estilo de programación, corrección y eficiencia de la implementación y calidad de los comentarios. El código debe ser original, por lo que

no se evaluará el trabajo si se detecta código copiado o descargado de internet

3. **Modelo seleccionado:** se valorará, tanto de manera absoluta como comparativamente con el resto de los trabajos, el comportamiento de los modelos en la tarea de predicción, así como el análisis exploratorio inicial (métricas relacionales / modelos de aprendizaje automático), así como la optimización de hiper-parámetros. El modelo seleccionado final debe estar claramente indicado y debe poder cargarse correctamente, en caso contrario este criterio se valorará con 0 puntos.
4. **Presentación y defensa** (factor multiplicativo): la nota final de cada estudiante del equipo estará condicionada por su participación en la defensa. De tal manera que la nota obtenida a partir de los tres apartados anteriores se multiplicará por un factor en el rango $[0,1]$ correspondiente a la calidad de la participación del estudiante en la defensa del trabajo. Se valorará la claridad de la presentación y la buena explicación de los contenidos del trabajo, así como especialmente, las respuestas a las preguntas realizadas por el profesor.

IMPORTANTE: cualquier plagio, compartición de código o uso de material que no sea original y del que no se cite convenientemente la fuente, significará automáticamente la calificación de cero en la asignatura para todos los alumnos involucrados. Por tanto, a estos alumnos no se les conserva, ni para la actual ni para futuras convocatorias, ninguna nota que hubiesen obtenido hasta el momento. Todo ello sin perjuicio de las correspondientes medidas disciplinarias que se pudieran tomar.

Referencias

- [1] Struyf J., Blockeel H. (2011) Relational Learning. In: Sammut C., Webb G.I. (eds) Encyclopedia of Machine Learning. Springer, Boston, MA. https://doi.org/10.1007/978-0-387-30164-8_719
- [2] Koschützki, D.; Lehmann, K. A.; Peeters, L.; Richter, S.; Tenfelde-Podehl, D. and Zlotowski, O. (2005) Centrality Indices. In Brandes, U. and Erlebach, T. (Eds.) *Network Analysis: Methodological Foundations*, pp. 16–61, LNCS 3418, Springer-Verlag.
- [3] S. Fortunato (2010). "Community detection in graphs". Phys. Rep. 486 (3–5): 75–174. arXiv:0906.0612. Bibcode:2010PhR...486...75F. doi:10.1016/j.physrep.2009.11.002. S2CID 10211629.
- [4] P. W. Holland & S. Leinhardt (1971). "Transitivity in structural models of small groups". *Comparative Group Studies*. 2 (2): 107–124. doi:10.1177/104649647100200201. S2CID 145544488.
- [5] Kolaczyk, E. D., & Csárdi, G. (2014). *Statistical analysis of network data with R* (Vol. 65). New York: Springer.
- [6] *Angles, Renzo; Gutierrez, Claudio (1 Feb 2008). "Survey of graph database models" (PDF). ACM Computing Surveys. 40 (1): 1–39. CiteSeerX 10.1.1.110.1072.*
- [7] Grover, Aditya, and Jure Leskovec. "node2vec: Scalable feature learning for networks." Proceedings of the 22nd ACM SIGKDD international conference on Knowledge discovery and data mining. 2016.
- [8] Wu, Lingfei; Cui, Peng; Pei, Jian; Zhao, Liang (2022). "Graph Neural Networks: Foundations, Frontiers, and Applications". Springer Singapore: 725.